装明白
装修报价可计算审计

把现实里数百种模糊叫法，映射到 119 个标准工序组成的坐标轴；
判断交给可解释的规则，每条结论带行号、基准、公式与判定指纹。

---

119 概念
388 别名 · 13 条规则

5 份
真实单据 · 603 行明细

243 测试
15 步自检 · 门禁全绿

3 指纹
冻结基线 · 离线可复算

边界先行：不判断贵不贵、不评价施工质量、不推断动机。只判漏没漏、重没重、算术与整单对不对得上。
参赛主体、队伍信息与报名状态以作品信息收集表为准。 | 生成时点 2026-11-05 | 仓库 commit 见第 9 页

装修报价缺的不是「看不懂」，是坐标系

同一道工序五种叫法、三种单位；业主拿 2–4 份报价，无法逐项比对。
我们把「能不能判」划清楚——判得少、判得准，比判得多、判得虚值钱。

只判这五类（都能被算术与文本裁决）

① 漏项：模板集合差 + 文本证据词
② 重复：同概念/工艺包含对（限同分区）
③ 单行算术：数量 × 单价 ≠ 合价
④ 整单对账：明细 + 取费 ≠ 印刷合计
⑤ 口径风险：按实结算 / 暂定 / 另计

一律不判（写了就是编）

× 贵不贵（不做虚高 / 最低价断言）
× 活儿好不好（不评价施工质量）
× 值不值（不推断动机、不指控造假）
× 最终结算价（没有决算数据就不预测）

低置信度结论不进核减金额，只进待确认清单

这一页对应官方「创新性」里最难讲清的部分：创新不在模型多大，而在把不可判定的命题挡在门外。

「想法到应用」不是口号，每一步有可复核产出

官方原文要求：体现华为云产品在需求理解、代码生成、项目构建、问题修复、部署上线各环节的使用价值。

环节	码道做了什么	可复核产出 / 证据
① **需求理解**	把「三类审计」写成可验收条款，逼出判据	`raw/stage1_requirement.txt`
② **代码生成**	只读数据补本体 18 个概念，不改判定代码	对齐覆盖率 53.3% → 83.3%（`git revert` 可回退复现）
③ **项目构建**	Dockerfile + .dockerignore + compose	人修掉 `curl` 健康检查 → 标准库探活
④ **问题修复**	空 CSV 从 500 改成分类返回 400	`EmptyRowsError` + 实测记录
⑤ **部署上线**	systemd + Nginx + 云上快速部署清单	RDS / OBS 命令行；沙箱 + DevBridge 出 HTTPS

诚实分工：码道做外围与本体（2 个作者 commit / 525 行 / 7 文件），人守判定与云原生。
2026-11-01 新增的 store/cache/llm 是人工开发，没有算成「码道生成」。

每个服务都在链路里有位置，状态如实写

官方要求「云上部署 + 可视化 Demo 页面」；15 条路由本地与沙箱均全 200。

服务	代码位置	实例 / 额度状态	材料怎么写
RDS PostgreSQL	`src/store.py`	已开通；连不上自动降级 SQLite	已接入并落库，/history 可查
DCS Redis	`src/cache.py`	需控制台创建 无 CLI 接口	代码已接入，实例待开通
MaaS 文本 / 视觉	`src/llm.py`	无 API Key；输出接地校验，失败退模板	当前解读标注「规则模板」
OCR 表格识别	`src/perception.py`	额度受限（11/04 复测 4106）	用历史产物 / 本地 Vision
OBS / ECS	部署手册	OBS 已开通；ECS 受余额限制	公网走沙箱 + DevBridge

红线：不写「Redis 已开通」「MaaS 已跑通真实照片」「公网永久可用」；DevBridge 隧道 72h 失效，可 5 分钟重建。

证据：09_证据附录/演示环境验证记录.md

判断力不在代码里，在三份 JSON 里

大模型只做「理解与表达」，裁决交给可解释的规则——这样结论才能被复算、被质疑、被复现。

① 感知层

照片 / PDF / Excel → 行项 JSON

逐行算术自校验

不判断对错

`perception.py · vision_ocr.py`

② 坐标系层

「批荡 / 刮腻子 / 批嵌」落到同一工序节点

不做结论

`ontology · templates · coverage`

③ 判断层

13 条规则跑漏 / 重 / 算术 / 对账

每条带行号+基准+公式

不写文案

`pipeline.py（零第三方依赖）`

④ 表达层

报告 / 问询单 / 审计包 / 校对台

可打印、可导出 Excel/PDF

不改判定

`inquiry.py · xlsx.py · make_bundle.py`

可迁移性已实测：引擎零改动，只换本体 / 模板 / 覆盖率三份 JSON，同一套 13 条规则能审汽修维保单（漏 4 / 重 1 / 对账差 30），并由此抓出 2 处隐式领域耦合并修掉。见 `迁移实验_汽修维保_1101.md`。

架构图：04_技术文档/装明白_技术架构图_4000x2500.png

5 份真实单据，603 行工序明细

四份家装照片转录 + 一份工装公开 PDF 坐标解析；汇总行单独分层，不进工序明细（否则总价翻倍）。

单据	工序行	对齐率	判定要点	冻结指纹
上海卓观 · 两房半包	127	87.4%	21 组变体排除后 0 重复	`2ab9413a`
花溪北岸 · 5 页施工报价	120	87.5%	口径风险聚合 12 → 3 条	`456e1bd9`
深圳新新 · 诊所装饰（工装）	168	67.3%	文本版 PDF 坐标分列	`3d33c49c`
上海翡翠台 · 老房全案	123	82.9%	对账抓出 11,711 元差额	黄金标注 8/8 召回
124㎡ · 基础报价单	65	95.4%	范围裁剪后精确率 0.22 → 0.67	范围内 4/4

17 个缺陷由真实数据打穿（含：汇总行重复加总、OCR 错字丢列、分页序号重复、工艺包含对跨区误扣）。

诚实边界：n=5 只作存在性证明；黄金标注只有 2 份、单一标注者 A1，不报「总体召回率」。

证据：09_证据附录/评测数字总表.md · 真实数据评测报告_v2.md

样本小，所以每个数字都给区间和出处

黄金标注（n=2，Wilson 95% CI）

0.833

auto 档精确率 / 召回率，CI 0.552–0.953

all 档召回 1.000（含待确认档），精确率 0.750

`python3 eval/golden_eval.py`

消融 L0 → L3（逐级证明组件贡献）

0.267 → 0.800

feitai auto 精确率；124㎡ auto 预测 28 → 19 → 9 → 3，补项金额 25,624 → 259

`python3 eval/ablation.py`

注入实验 242 / 242

下限校验 **不是召回率。**给 5 份真实单据埋程序已知答案的缺陷（删整项 / 复制行 / 改金额 / 数量归零 / 加「另计」），测规则能否抓到并指对行。

第二标注一致性：尚未完成

盲标页 + Cohen's κ 脚本已交付（30 分钟/份），但**还没有第二个人跑过。**在此之前，材料只写「单一标注者、结果可复算」，不写「标注可靠」。

可复现 · 差异化最强的一页

「可复现」不是口号，是可以交给评委的包

同样输入 + 同样标准 + 同样代码 → 同样结论；改一个数字，立刻对不上。

审计包 + 离线校验器

59KB 的 zip：输入 CSV + 六份标准 + 当时代码 + 判定摘要。

`python3 verify.py` → PASS；把 280 改成 281 → FAIL（输入 sha256 不符）。

判定指纹

三份冻结预测：`2ab9413a` / `456e1bd9` / `3d33c49c`。

改任何规则或本体导致漂移，必须解释原因；报告封面带报告编号与指纹。

报告编号 + 证据链

每条结论带原表行号、对照基准、计算公式、证据强度分与三档处置（自动通过 / 建议复核 / 转人工）。

本地 OCR 闭环（同一套判定，只换输入）：原始 OCR 对齐 40.0%、明细合计少 68,892 元；人工校对后 82.9%、合计对得上。 **先对账、再判漏项**是唯一能发现 OCR 丢钱的手段。

每一句主张，都给一条能当场跑的命令

命令	期望看到	对应主张
`git clone gitee.com/Cwt66/zhuangmingbai` 或 `github.com/cwt66/zhuangmingbai`	双仓同一 commit；MIT；GitHub Actions CI 绿	开源 / 落地进展
`bash scripts/check_all.sh`	243 tests OK · 15 步 · **五份**指纹一致 · 规则活性 35/47 · `[ALL GREEN]`	工程可信度
`python3 scripts/gate_report.py`	5 单全**可交付**；5 个故障注入 **5/5 全拦**	报告会拒绝交付自己
`python3 eval/redteam.py`	8 招攻击 **拦住 7**；得手那招有断言拦不住的测试	主动打自己
`python3 eval/golden_eval.py` + `injection_test.py`	auto P/R 0.833（CI 0.552–0.953）；注入 242/242（下限，非召回率）	评测口径
`make_bundle.py ...` → `verify.py`	PASS；改一个数字 → FAIL	可复现
`python3 scripts/audit_one.py 报价单.csv`	一条命令出结果；非报价单返回 400 并说明理由	码道 Skill 的入口
`python3 scripts/diff_quotes.py a.csv b.csv`	差额 +664.00；增350 − 减98 + 调整412，差 **0.00**	两版对比
`python3 eval/rule_liveness.py`	47 个变异被杀 35；判定字段存活 **0**（首次 17）	规则真的在起作用
打开 `Pages /replay/`	5 单 / 86 条结论；点一条结论高亮它指向的原表行	可点回放
`python3 scripts/audit_with.py ...`（汽修）	引擎零改动，漏 4 / 重 1 / 对账差 30	可迁移性

改一行 CSV → `snapshot_predictions.py --check` 看指纹漂移 → `git checkout` 恢复。 在线 main `c56b706`；v0.5.0 快照 `2391a0a`（相差 19 个提交，判定口径未变）。

诚实边界 · 下一步

能跑的系统、能查的数字、能承认的边界

还不能说「已完成」

- 0 个真实家庭试点（应用价值唯一硬证据）
- MaaS 无 Key，云端 OCR 额度受限
- Redis 实例需控制台创建
- **红队 8 招有 1 招得手**（㎡ 写成 m，见负向库 NA13）
- 鲲鹏实例未实测，不写「已适配」
- 3 分钟演示视频未录
- 报名与队伍信息未填（11/30 截止）

按性价比排的下一步

P0 报名 + 队伍信息（逾期 = 弃赛）
P0 2–3 个真实家庭试点（签合同前介入）
P1 收 1–2 对「报价 + 结算」，验证漏项是否真变成加钱
P1 视频 + Redis 控制台 + 云上固定地址
P2 第二标注者跑盲标，算 Cohen's κ

MIT	243	0
开源许可	单元测试全绿	编造的真实用户数

仓库 `https://gitee.com/Cwt66/zhuangmingbai` | 唯一对外数字口径 `09_证据附录/评测数字总表.md`

评委对「诚实 + 有证据」的容忍度，远高于「完美 + 被戳穿」。